

Escopo de Entregas - Mentoria de Dados

Projeto: Produto de Dados do Mercado de Criptomoedas

1. Visão Geral do Projeto

Objetivo

O presente projeto visa conceber, desenvolver e implementar um produto de dados analítico focado no mercado de criptomoedas. A solução consolidará dados históricos e diários de ativos digitais, fornecendo uma base robusta, escalável e de alta performance para tomada de decisão, monitoramento de volatilidade e análise de sentimento de mercado.

Contexto

O projeto serve como mentoria, estruturado especificamente para exercitar competências críticas em engenharia e análise de dados. Entre os pilares práticos avaliados estão o desenvolvimento de ingestão batch agendada, implementação de arquitetura de dados em camadas, aplicação de regras estritas de qualidade de dados e construção de modelagem analítica robusta. O ecossistema tecnológico é composto pelo Databricks atuando como motor de ingestão e processamento, e pelo Power BI como a camada unificada de apresentação e consumo analítico.

Estratégia de Entrega Incremental

Dado que o escopo analítico total é amplo para a dinâmica de mentoria, a abordagem de implementação adota uma estratégia incremental dividida em três fases bem delineadas. Sob uma rígida governança de gerenciamento de projetos, **uma fase só poderá ser iniciada quando a anterior estiver completamente funcional e validada de ponta a ponta**, mitigando riscos de integração e acelerando a entrega de valor real.

2. Escopo Geral da Solução

- **Fontes de Dados:** O ecossistema consumirá dados transacionais e de preços diretos de exchanges de criptomoedas, dados históricos consolidados e metadados, além de índices consolidados de sentimento de mercado.
- **Arquitetura:** Implementação da Arquitetura Medallion estruturada sobre o ecossistema Delta Lake. O fluxo consistirá na camada Bronze para armazenamento de dados crus e históricos (append-only), na camada Silver para higienização, deduplicação e padronização dos schemas, e na camada Gold para consolidar tabelas analíticas perfeitamente agregadas.
- **Processamento:** Toda a engenharia de dados e cargas de ETL serão executadas por meio de jobs automatizados e agendados em lote (batch) utilizando o Databricks Workflows, parametrizados de acordo com a frequência ótima permitida por cada fonte de origem.
- **Consumo Analítico:** Construção de dashboards corporativos de alta performance no Power BI, projetados para exibir séries temporais históricas, visões comparativas de ativos e correlações avançadas entre métricas de sentimento e variações financeiras.

3. Entrega 1 – Pipeline de Preço (MVP)

Objetivo

Validar a arquitetura inteira do produto de dados de ponta a ponta, garantindo que a infraestrutura técnica e o fluxo de dados estejam integrados do Databricks ao Power BI.

Escopo Técnico

- **Ingestão:** Extração via carga batch agendada dos dados de OHLCV (open, high, low, close, volume) provenientes de endpoints públicos REST gratuitos de uma única exchange de referência (a ser selecionada entre Binance, Coinbase ou Kraken).
- **Camada Bronze (Delta Lake):** Gravação dos dados crus recebidos da API no formato original (append-only), aplicando obrigatoriamente um campo de timestamp de ingestão para controle de auditoria, sem qualquer transformação adicional.
- **Camada Silver (Delta Lake):** Aplicação de rotinas automatizadas de deduplicação de registros, conversão e validação estrita de tipos de dados e padronização mandatória do timezone para o padrão UTC (visto que o mercado cripto opera 24/7).
- **Camada Gold (Delta Lake):** Estruturação de tabelas agregadas iniciais contendo as métricas básicas de preço diário por moeda, prontas para serem lidas diretamente pelas ferramentas de visualização.
- **Orquestração e Qualidade:** Configuração do pipeline via Databricks Workflows. Inclusão de tratamento nativo de rate limit com lógica de backoff/retry, mecanismos de idempotência e checagens automáticas de qualidade de dados contra valores nulos, lacunas (gaps) de datas e valores absurdos como preço zero ou negativo.
- **Log de execução dos jobs e versionamento:** Implementação de um histórico de execução de todos os jobs, garantindo que haja rastreabilidade. Ademais, fazer todo o versionamento do código de ingestão e transformação.

Escopo Power BI

Página 1 – Visão de Preço

- **Indicadores:** Último preço disponível do ativo capturado e variação percentual do preço no período selecionado.
- **Visualizações:** Gráfico de linha de série temporal do preço de fechamento histórico e gráfico de barras para o volume negociado no tempo.
- **Filtros:** Filtro interativo por período de análise.

Entregáveis

- Notebooks operacionais e jobs configurados no Databricks Workflows para ingestão e transformação.
- Tabelas Delta provisionadas e populadas nas camadas Bronze, Silver e Gold para o ativo da exchange selecionada.
- Arquivo de relatório do Power BI (.pbix) contendo a página inicial estruturada de Visão de Preço.
- Documentação técnica inicial detalhando os schemas e as fontes de dados mapeadas.

Critérios de Aceite

- O pipeline deve executar de forma 100% automatizada e agendada, sem qualquer necessidade de intervenção manual.
- A reexecução do pipeline ou de recargas históricas não pode gerar duplicidade de registros na base de dados.
- **O Power BI deve consumir os dados diretamente da camada Gold. A camada Gold deverá disponibilizar os dados já preparados para consumo analítico, minimizando a necessidade de transformações adicionais no Power BI, que atuará principalmente como camada de visualização e consumo analítico.**
- O dashboard deve responder e recalcular os indicadores corretamente ao manipular o filtro de período.
- A origem dos dados da exchange e os schemas de cada camada devem estar plenamente documentados.

Itens Fora do Escopo

- Ingestão de dados de múltiplas exchanges ou de agregadores.
- Cálculo de métricas estatísticas avançadas como volatilidade, correlações e dominância de mercado.
- Ingestão ou cruzamento com dados do índice de sentimento de mercado Fear & Greed.
- Execução de ordens transacionais ou recomendações de investimentos.

Premissa de Projeto para a Entrega 1: Para fins de viabilização do MVP, as métricas visuais de preço atual e variação percentual no Power BI aplicar-se-ão estritamente à moeda única configurada na primeira exchange conectada, validando a integridade estrutural antes da expansão para multiativos.

4. Entrega 2 – Comparativo e Mercado

Objetivo

Expandir o produto de dados para suportar análises comparativas e métricas estatísticas avançadas de mercado cruzando múltiplos ativos digitais (Bitcoin e altcoins).

Escopo Técnico

- **Inclusão de Múltiplas Moedas:** Expansão das conexões para coletar informações de múltiplas criptomoedas simultaneamente. **Poderão ser utilizados agregadores de mercado quando necessários para complementar informações de market cap, dominância ou metadados das moedas.**
- **Tratamento Silver:** Ativação de rotinas avançadas para normalização e de-para de nomes de moedas e símbolos (Ex: padronização de siglas idênticas vindas de fontes e exchanges diferentes). Implementação de resiliência automatizada no pipeline para que a adição de novas moedas ou descontinuação de ativos nas APIs não causem quebras ou interrupções no fluxo.
- **Cálculo de Métricas (Camada Gold):** Implementação de scripts de engenharia analítica para gerar:

- Retorno acumulado normalizado (base 100) por moeda, viabilizando a comparação direta da performance de ativos com patamares de preços distintos em uma mesma escala.
- Volatilidade: Cálculo estatístico do desvio-padrão dos retornos com base em janelas temporais dinâmicas ou pré-definidas.
- Correlação: Geração de matrizes estatísticas de correlação entre o comportamento de preço do Bitcoin e das altcoins selecionadas.
- Dominância do Bitcoin: Cálculo diário da proporção do market cap do BTC sobre o valor total do mercado cripto.

Escopo Power BI

Página 1 – Visão Geral de Mercado

- **Indicadores:** Tabela de preços atuais de mercado, variação percentual nas últimas 24 horas para cada moeda e percentual atualizado da dominância do BTC.

Página 2 – Comparativo BTC x Altcoins

- **Visualizações:** Gráfico de linhas comparativo exibindo o retorno acumulado normalizado em base 100 de várias moedas selecionadas e uma matriz visual de correlação estatística interativa.
- **Filtros:** Filtros globais sincronizados de seleção de moeda e período em todas as páginas do relatório.

Entregáveis

- Notebooks e jobs atualizados no Databricks suportando loops dinâmicos de multiativos e conexões flexíveis.
- Tabelas Delta expandidas e otimizadas na Gold contendo as métricas calculadas de retorno, volatilidade, correlação e dominância.
- Arquivo .pbix do Power BI atualizado, contendo agora as duas páginas completas de análise de mercado e comparação.
- Documentação de schemas atualizada detalhando as fórmulas estatísticas aplicadas e novos mapeamentos das tabelas analíticas.

Critérios de Aceite

- O pipeline expandido de multiativos opera de forma agendada no Databricks Workflows sem falhas.
- As moedas adicionadas ou removidas dinamicamente nas APIs não interrompem a carga diária programada.
- **O Power BI deve consumir os dados diretamente da camada Gold. As transformações analíticas devem ocorrer prioritariamente no Databricks, e a camada Gold deverá disponibilizar os dados já preparados para consumo analítico, minimizando a necessidade de transformações adicionais no Power BI, que atuará principalmente como camada de visualização e consumo analítico.**
- Os filtros de moedas isolam e atualizam os gráficos comparativos corretamente de forma cross-report.

- A documentação de governança de dados reflete precisamente a estrutura analítica gerada para a comparação de mercado.

Itens Fora do Escopo

- Ingestão ou processamento de indicadores de sentimento de mercado (Fear & Greed Index).
- Modelagem de dados baseada em redes sociais de acesso restrito ou pago (X/Twitter, Reddit).

Premissa de Projeto para a Entrega 2: O ranking visual de desempenho demandado no painel comparativo será gerado dinamicamente na interface do Power BI utilizando-se estritamente como insumo as tabelas consolidadas de retorno acumulado geradas previamente na camada Gold do Databricks.

5. Entrega 3 – Sinais Externos e Sentimento

Objetivo

Enriquecer a camada analítica integrando fatores comportamentais externos ao produto de dados através da inclusão e alinhamento do indicador de sentimento de mercado Fear & Greed.

Escopo Técnico

- **Ingestão:** Conexão batch automatizada com a API pública e gratuita do Crypto Fear & Greed Index (alternative.me), extraindo o histórico completo da série diária do indicador.
- **Processamento e Modelagem:** Tratamento do dado recebido como um indicador sintético já calculado pelo provedor, eliminando qualquer necessidade de concepção ou treinamento de modelos internos de inteligência artificial ou processamento de linguagem natural.
- **Alinhamento Temporal (Camada Gold):** Desenvolvimento de rotinas de consolidação para realizar o perfeito alinhamento e junção (join) temporal por data entre a série diária do índice de sentimento e as séries de preços e retornos históricos consolidados das moedas.
- **Análise de Tendência:** Geração na camada Gold de tabelas que mapeiem e sustentem a correlação estatística para avaliar se as viradas do índice de sentimento antecedem (sinalizador de tendência) ou seguem (reação de mercado) os movimentos expressivos de preço.

Escopo Power BI

Página 1 – Sentimento de Mercado

- **Indicadores:** Valor atual do índice Crypto Fear & Greed e sua respectiva classificação qualitativa textual (ex: Medo Extremo, Medo, Neutro, Ganância, Ganância Extrema).
- **Visualizações:** Gráfico de série temporal do comportamento histórico do índice de sentimento e gráfico combinado com a série histórica do Fear & Greed sobreposta graficamente à série de preços dos principais ativos. Adição de uma visualização

analítica demonstrando a correlação de atraso/avanço entre sentimento e oscilação de preço.

Página 2 – Dashboard Executivo Consolidado

- **Consolidação:** Painel central unificado que reúne de forma concisa e de alto nível as principais visões geradas ao longo de todo o ciclo de vida do projeto: preços atuais de mercado, variações de curto prazo, dominância consolidada do BTC, retornos acumulados comparativos e os índices de sentimentos vigentes.
- **Filtros:** Manutenção estrita dos filtros globais por moeda e intervalo de período em todas as abas.

Entregáveis

- Scripts finais de ingestão e notebooks de modelagem analítica preço-sentimento agendados no Databricks.
- Tabelas Delta definitivas nas camadas Bronze, Silver e Gold englobando de forma harmonizada dados transacionais e de sentimentos.
- Arquivo final do Power BI (.pbix) com a estrutura analítica completa contendo todas as páginas especificadas nas fases do escopo.
- Documentação de dados completa e encerrada, contendo dicionário de dados, mapeamento de schemas e diagramas de linhagem de todas as fontes exploradas.

Crítérios de Aceite

- O ecossistema completo opera em regime de produção automatizada via Databricks Workflows.
- As reexecuções parciais ou totais do pipeline mantêm a integridade absoluta dos dados sem gerar anomalias ou duplicidades.
- **O Power BI deve consumir os dados diretamente da camada Gold. As transformações analíticas devem ocorrer prioritariamente no Databricks, de modo que a camada Gold disponibilize os dados já preparados para consumo analítico, minimizando a necessidade de transformações adicionais no Power BI e consolidando o seu papel principal como camada de visualização e consumo analítico.**
- Todos os painéis respondem de forma ágil e precisa aos filtros de tempo e ativos de ponta a ponta.
- Todas as fontes de dados e tabelas analíticas estão 100% documentadas sob as melhores práticas de governança.

Itens Fora do Escopo

- Desenvolvimento interno de rotinas proprietárias de Machine Learning ou raspagem de dados (web scraping) para mensuração própria de sentimentos.
- Ingestão de feeds de redes sociais comerciais por restrições operacionais e financeiras de acesso.
- Integração transacional com APIs de negociação de exchanges de criptomoedas.

6. Dependências e Premissas

Dependências Críticas

1. **Disponibilidade de Endpoints:** O sucesso das cargas diárias depende da estabilidade operacional contínua e da imutabilidade das estruturas das APIs públicas gratuitas fornecidas pelas exchanges (Binance, Coinbase ou Kraken), agregadores de mercado (caso sejam adotados para complementar dados específicos) e o portal Alternative.me.
2. **Infraestrutura Cloud:** Garantia de conectividade ininterrupta e disponibilidade operacional dos ambientes de nuvem configurados para o Databricks (computação e workflows) bem como o acesso ao gateway de atualização programada do Power BI Service para o consumo dos relatórios.

Premissas de Projeto

- **Premissa 1 (Rate Limits):** Assume-se estritamente que as coletas de dados adotarão uma frequência de agendamento compatível com as restrições e limites de requisição (rate limits) vigentes nas documentações oficiais de cada tier gratuito, de modo a evitar o bloqueio temporário das chaves ou IPs de ingestão.
- **Premissa 2 (Qualidade na Origem):** O projeto assume que dados incorretos oriundos das APIs externas serão mitigados pelas checagens e limpezas executadas na camada Silver, mas anomalias severas na própria origem deverão ser notificadas via logs de execução.
- **Premissa 3 (Faseamento Rígido):** Não haverá avanço de esforço técnico de uma fase para outra sem que os critérios de aceite estabelecidos para a etapa anterior tenham sido homologados funcionalmente de ponta a ponta.
- **Premissa 4 (Modelagem Centralizada):** Toda e qualquer lógica complexa de agregação estatística ou junção de séries temporais deve ser tratada nativamente na camada Gold do Databricks, assumindo-se o princípio de que o Power BI atuará exclusivamente como uma camada magra de renderização e consumo analítico.

7. Critérios Gerais de Aceite

Para que o produto de dados consolidado seja formalmente aceito ao término do ciclo de vida do projeto, a solução deve atender obrigatoriamente aos seguintes critérios unificados:

3. **Automação Integral:** O pipeline completo de processamento de dados executa do início ao fim de forma agendada no Databricks Workflows, sem necessitar de nenhuma ação ou intervenção operacional manual.
4. **Idempotência Estrutural:** Qualquer reexecução de cargas de dados programadas ou retroativas (backfill) não gera, sob nenhuma circunstância, registros duplicados ou dados corrompidos nas tabelas Delta Lake.
5. **Performance de Consumo:** A camada Gold serve as tabelas perfeitamente agregadas e formatadas, garantindo que o Power BI consuma a informação de maneira direta, performática e livre de rotinas pesadas de modelagem ou transformação em DAX/Power Query no ambiente de BI.
6. **Consistência de Filtros:** Todos os componentes analíticos visuais integrados nos relatórios do Power BI devem responder e filtrar as informações de forma sincronizada, rápida e correta de acordo com as seleções de ativos e recortes temporais efetuadas pelos usuários.

7. **Rastreabilidade e Governança:** Cada componente de dado persistido no lago possui mapeamento completo de sua origem de extração e documentação explícita dos schemas técnicos de todas as três camadas Medallion estruturadas.

8. Matriz de Rastreabilidade dos Requisitos

Requisito Original	Entrega Responsável	Componente Impactado	Observações
Ingestão OHLCV	Entrega 1	Pipeline Databricks (Bronze)	Carga batch inicial para capturar o histórico e dados diários de uma única exchange de referência.
Arquitetura Bronze/Silver/Gold	Entrega 1	Delta Lake (Databricks)	Implementação obrigatória do ecossistema Medallion para fins de governança, limpeza e modelagem.
Dashboard Básico de Preço	Entrega 1	Power BI (Página 1)	Criação da primeira visualização (série temporal e volume) validando a integração da solução de ponta a ponta.
Múltiplas Moedas	Entrega 2	Ingestão Databricks / Camada Silver	Expansão estrutural do fluxo para suportar loops dinâmicos e resiliência na ingestão de múltiplos ativos.
Retorno Normalizado Base 100	Entrega 2	Camada Gold / Power BI	Cálculo analítico de performance processado no Databricks e exibido em escala comparativa unificada no BI.
Volatilidade	Entrega 2	Camada Gold (Databricks)	Processamento matemático do desvio-padrão dos retornos calculados em janelas temporais diretamente no cluster.
Correlação BTC x Altcoins	Entrega 2	Camada Gold / Power BI	Matriz estatística gerada na camada Gold e mapeada visualmente de forma interativa no relatório.
Dominância do Bitcoin	Entrega 2	Camada Gold (Databricks)	Monitoramento diário da proporção de market cap, habilitado condicionalmente por agregadores se necessário.
Fear & Greed Index	Entrega 3	Ingestão Databricks (Bronze/Silver)	Extração diária automatizada da API de sentimento de terceiros, sem necessidade de processamento interno de NLP.
Alinhamento Temporal Preço x Sentimento	Entrega 3	Camada Gold (Databricks)	Execução de junção técnica (join) cronológica entre a série do

Requisito Original	Entrega Responsável	Componente Impactado	Observações
			Índice e o comportamento histórico dos preços.
Dashboard Executivo Consolidado	Entrega 3	Power BI (Página 2)	Centralização final e de alto nível de todos os principais KPIs técnicos e de negócio construídos no projeto.

9. Cronograma Evolutivo das Entregas

Fase	Objetivo Principal	Entrega Técnica (Databricks)	Entrega Analítica (Power BI)	Valor Gerado
Entrega 1 (MVP)	Validar a infraestrutura básica e a arquitetura técnica completa ponta a ponta.	Ingestão batch de dados OHLCV de uma única exchange; persistência estruturada nas camadas Bronze, Silver e Gold com rotinas básicas de qualidade e idempotência.	Página de Visão de Preço: Exibição da série temporal de fechamento, volumes e KPIs básicos de variação de preço para um único ativo com filtro de período.	Homologação ágil de todo o ecossistema tecnológico e fornecimento imediato de dados históricos limpos e confiáveis de preço para análise de um ativo âncora.
Entrega 2 (Mercado)	Expandir as capacidades analíticas do ambiente para	Ingestão expandida para múltiplas criptomoedas; normalização estrutural	Página de Visão Geral de Mercado + Página de Comparativo: Painel de preços atuais,	Capacitação analítica

Fase	Objetivo Principal	Entrega Técnica (Databricks)	Entrega Analítica (Power BI)	Valor Gerado
	suportar multiativos e inteligência comparativa de mercado.	de símbolos e cálculo nativo na Gold das métricas de retornos base 100, volatilidade, correlação e dominância (com uso condicional de agregadores).	variação 24h, dominância do BTC, gráficos de retorno normalizado e matriz interativa de correlação de ativos.	para tomada de decisões estratégicas com base no comportamento de altcoins comparadas ao Bitcoin, identificação de forças relativas e correlações estatísticas setoriais.
Entrega 3 (Sinais)	Incorporar contexto comportamental de sentimento de mercado às análises de oscilação financeira.	Ingestão da série diária do índice Crypto Fear & Greed; rotinas automatizadas na Gold para alinhamento temporal por data e modelagem de tendências preço-sentimento.	Página de Sentimento + Dashboard Executivo Consolidado: Gráficos de sentimento no tempo, sobreposição de Fear & Greed ao preço, gráficos de lead/lag e centralização unificada dos KPIs macros desenvolvidos.	Geração de uma visão holística avançada que une dados quantitativos de preços a fatores psicológicos

Fase	Objetivo Principal	Entrega Técnica (Databricks)	Entrega Analítica (Power BI)	Valor Gerado
				de mercado, permitindo analisar se o sentimento coletivo atua como indicador antecedente ou consequente das tendências.

10. Resumo Executivo

O presente plano estratégico estabelece o roteiro detalhado para a concepção e implementação do produto de dados analítico voltado ao mercado de criptomoedas. Alinhado a um direcionamento essencialmente pedagógico focado nas melhores práticas modernas de engenharia e governança de dados, o projeto adota uma arquitetura computacional baseada no Databricks e no ecossistema de armazenamento transacional Delta Lake, culminando no consumo analítico de alta performance via Power BI.

A divisão metodológica em três entregas incrementais assegura uma significativa mitigação de riscos, validando continuamente a infraestrutura antes de elevar o nível de complexidade das análises. O ciclo inicia-se na Entrega 1 (MVP) com foco exclusivo no estabelecimento do fluxo de engenharia de ponta a ponta e na garantia de qualidade para os dados de preço de um ativo inicial. A Entrega 2 expande substancialmente as fronteiras do produto ao unificar a ingestão para múltiplas moedas e processar, diretamente na camada Gold, indicadores estatísticos essenciais como volatilidade, dominância e retornos normalizados, prevendo o uso de agregadores de mercado estritamente como suporte condicional a métricas de metadados. Por fim, a Entrega 3 consolida a maturidade analítica da plataforma ao cruzar as variáveis transacionais com o índice macro de sentimento Fear & Greed, entregando ao usuário final um cockpit executivo completo capaz de correlacionar movimentos comportamentais e flutuações de preços. Respalado por critérios severos de automação, centralização de processamento no Databricks e rastreabilidade por meio de uma matriz estruturada de requisitos, este documento define o escopo definitivo e serve de diretriz mandatória para a execução e aceitação do projeto.